XTuner微调LLM

1. Finetune简介

o 两种Finetune范式

增量预训练模型: 让基座模型学习到一些新的指示,如某个垂直领域的尝试,训练数据是一些文章,书籍或者代码等

指令跟随微调: 让模型学会对话模板,根据人类指令进行对话。训练数据是一些高质量的对话,问答数据等



○ 一条数据的一生

1. 原始数据-->标准格式数据

2. 标准格式数据-->添加对话模板

2. XTuner介绍

LoRA: 通过在原本的Linear旁,新增一个支路,包含两个连续的小Linear,新增的这个之路通常叫做Adapter,Adapter参数量远小于原本的Linear,能大幅度降低训练的显存消耗

QLoRA:

。 **傻瓜化**:以配置文件的形式封装了大部分微调场景,0基础的非专业人员也能一键开始微调

• 轻量级:对于7B参数量的LLM,微调所需要的最小显存仅为8GB

3. XTuner快速上手

1. 安装

```
pip install xtuner
```

2. 挑选配置模板

```
xtuner list-cfg -p internlm_20b
```

3. 拷贝配置模板

```
xtuner copy-cfg internlm_20b_qlora_oasst1_512_e3 ./
```

4. 修改配置模板

```
vi internlm_20b_qlora_oasst1_512_e3_copy.py
```

5. 启动训练

```
xtuner train internlm_20b_qlora_oasst1_512_e3_copy.py
```

Config命名规则:

模型名 internIm_20b 无 chat 代表是基座模型 使用算法 qlora 数据集 oasst1 数据长度 512 Epoch e3, pepoch 3

常用超参

data_path
max_length
pack_to_max_length
高
accumulative_counts
数
evaluation_inputs

@ valuation_freq

数据路径或 HuggingFace 仓库名
单条数据最大 Token 数,超过则截断
是否将多条短数据拼接到 max_length,提
GPU 利用率
梯度累积,每多少次 backward 更新一次参
训练过程中,会根据给定的问题进行推理,
于观测训练状态
Evaluation 的评测间隔 iter 数