一、RAG的概括:

检索增强生成,他是一种结合了检索模型和生成模型的技术。通过从数据源中检索信息来辅助大预言模型生成答案。用户向模型提问,模型以搜索算法找到的信息未背景上下文,这些查询和检索到的上下文信息会被整合并发送给大预言模型的提示中。 能够解决大语言模型再处理知识密集型任务时,可能遇到的挑战。提供更加准确的回复,降低成本实现外部记忆。

二、向量数据库:

- 1、数据存储:将文本及其他数据通过其他预训练的模型转换为固定长度的向量标识,这些向量能够捕捉文本的语义信息。
- 2、相似性检索:根据用户的查询向量,使用向量数据库快速的找出最相关的向量的过程。通常通过计算余弦相似度 或其他相似度(点乘)来完成。检索结果根据相似度得分进行排序,最相关的文档将被用于后续的文本生成
- 3、向量表示的优化:包括使用更高级的文本编码技术,如句子嵌入或段落嵌入,以及对数据库进行优化以支持大规模向量搜索

三、RAG的三种范式:

1、Naive RAG: (问答系统, 信息检索) 索引, 检索, 生成

索引阶段,原始数据被清洗,提取并转换成标准化的文本块。 检索阶段使用编码其模型将用户的查询转换为向量表示,然后计算与索引中文本块的相似度,以检索最相关的信息。 最后,再生成阶段,模型根据检索到的信息合成响应。

2、Advanced RAG: (摘要生成,内容推荐)

在Naive RAG的基础上增加了预检索和后检索优化。 通过优化数据索引,微调嵌入模型和重新排序检索结果来提高检索质量。 可能换包括提示工程,即改进LLM提示以提高生成内容的质量和相关性。

3、Modular RAG: (多模态任务,对话系统)

是一种高度可扩展的凡是,他将RAG系统分解成多个模块,每个模块专注于RAG流程的一个特定的部分。 这种模块 化方法允许更加灵活的配置和优化,以适应不同的应用场景和需求。 可以包括递归检索和查询引擎,以在流程的后期提供更多上下文信息,从而在效率和响应深度之间取得平衡。

四、常见的集中优化方法:

RAG 常见优化方法 索引优化 嵌入优化 上下文管理 查询优化 Indexing Optimization **Embedding Context Curation** Query Optimization Optimization ✓ 重排 (rerank)✓ 上下文选择/压缩 ✓ 查询扩展、转换 ✓ 多查询 ✓ 细粒度分割 ✓ 结合稀疏和密集 (Chunk) ✓ 元数据 检索 ✓ 多任务 递归检索 Recursive Retrieval 迭代检索 Iterative Retrieval 自适应检索 Adaptive Retrieval LLM微调 **LLM Fine-tuning** ✓ 迭代细化搜索查询 ✓ 链式推理 (Chain-✓ Flare , Self-RAG✓ 使用LLMs主动决 ✓ 根据初始查询和迄 今为止生成的文本 ✓ 生成微调 of-Thought)指导检索过程 ✓ 双重微调 进行重复搜索 定检索的最佳时机 和内容

五、优化方法比较:

	model Adaptation	External Knowledge
Prompt Engineering	low	low
RAG	low	High
Fine-tuning	High	low
All of the above	High	High

六、评测:

1、经典的评估指标:

准确率、召回率、F1分数、BLEU分数、ROUGE分数

2.RAG评测框架:

基准测试: RGB、RECALL、CRUD

评测工具: RAGAS、ARES、TruLens

对话:

聊天测试.





聊天测试





- 3. 参考文献不少于10篇。
 4. 完成调试工作,要有完整的测试结果和给出各种参数指标。
 5. 当涉及到有关电路方面的内容时,必须完成调试工作,要有完整的测试结果和给出各种参数指标。
 6. 当涉及到有关计算机软件方面的内容时,要进行计算机演示程序运行和给出运行结果。
- 7. 参考文献不少于10篇。

参考文档:

阳光学院本科生毕业论文(设计)撰写规范.pdf

☞ 你叫什么?

我是一名由上海人工智能实验室开发的AI语言模型,名叫书生浦语。

多考文档

阳光学院本科生毕业论文(设计)撰写规范.pdf

支持输入文字、emoji 和粘贴图片

发送